

Atelier IA en santé

Janvier 2026

Tristan Margaté

2026-01-19

Table of contents

- Présentation
- Programme de l'atelier
- Outils
- Data
- Analyse de survie et modèle prédictif

Présentation

Présentation

Mon parcours

- Baccalauréat scientifique sciences de l'ingénieur (2018)
- Classe préparatoire scientifique MPSI - MP (2018 - 2020)
- Licence de mathématiques fondamentales / appliquées (2020 - 2021)
- Master de mathématiques appliquées (2021 - 2022)
- Master 2 de Data science spécialisé en santé (2022)




Mes expériences

- Stage : l'inférence causale en santé, Laboratoire universitaire (2022)
- Stage : ingénieur de recherche Dassault Systèmes (2023)
- Ingénieur de recherche à Dassault Systèmes depuis novembre 2023.
- Doctorat CIFRE (Dassault Systèmes x INRIA) depuis décembre 2024



Présentation de Dassault Systèmes



25 000

collaborateurs à travers
le monde



+370 000

clients



184

bureaux

Introduction de l'atelier

Objectif :

- Présentation de projets qui peuvent exister dans le monde industriel dans le domaine de la santé
- Présentation de mon travail, de mon quotidien et des compétences dont j'ai besoin pour mon travail
- Présentation du sujet “fil rouge” qui nous suivra pendant l'atelier
- Présentation des outils standards de l'industrie. vous allez les pratiquer (uv, git, python, pytorch)

Agenda :

- Lundi 5 janvier (9h - 13h)
- Lundi 12 janvier (9h - 13h)
- Lundi 19 janvier (9h - 13h)
- Lundi 26 janvier (9h - 13h)
- Lundi 2 février (9h - 13h)
- Lundi 2 février (14h - 18h)

Et vous?



Quel est votre parcours?

Qu'envisagez-vous pour la suite ? (stage, poursuite en thèse)

Dans quel domaine ?

Projet Living Heart

- Premier jumeau numérique complet simulant fidèlement la mécanique et l'électricité du cœur humain.
- Permet la planification chirurgicale personnalisée et le test virtuel de nouveaux dispositifs médicaux.
- Collaboration mondiale validant la simulation comme alternative aux essais cliniques.
- Utilisé au Boston Children's Hospital pour sécuriser les chirurgies complexes de ventricules inversés.




Projet MediTwin

Context : Virtual Twin For Healthcare



Healthcare systems



Patient



Hospital

Virtual twins of humans will transform healthcare

December 8, 2020
By Alyssa Ross

Today, we kick off our 6th annual Living Heart Symposium. This virtual event focuses on inventing new ways of representing life, specifically by creating the virtual twin of the human body.



We just completed a paper on this same topic, which we today unveil in coordination with the symposium. We invite you to download this paper, Virtual Twin of Humans: The Next Horizon in Healthcare.

The paper explores a transformative level of healthcare that we're on the cusp of achieving: patient-centric digital health. Bringing this vision to life requires creating a digital medical system with a detailed view of each patient's anatomy, biology and life exposure. This system must capture the vast amounts of data generated about each individual and connect that with knowledge from researchers and clinicians from around the globe. The system must also be available to a patient's entire care team. The unifying vision behind this is a virtual twin: an integrative reference of personal health information.

[white paper](#)




2020
Virtual Twin
Experience
of Humans




Projet MediTwin

VIRTUAL TWIN FOR NEXT GENERATION OF HEALTH CARE



Projet MediTwin

Reimagining medical practices with a virtual twin approach to improve patient outcomes




Projet Genesis : peau artificielle

GENESIS PROJECT OBJECTIVES

An **unsatisfied** medical need for **320 000** patients per year associated
with **long pain** for patients & **elevated costs** for payers


Diabetic foot ulcers



220 000/an


89 000/an

BIG 5



- 5 to 6 month to heal
- Long and multiple hospitalizations
- Multiple interventions with current market solutions
- Unfollowed > high risk for amputation

Severe burn victims



10 000/an

4 900/an

BIG 5




- Skin grafts from patient as only solution
- Needs multiple surgical interventions
- Donor sites need long healing leaving scars
- Existing skin substitutes only usable while waiting for grafts



Projet Genesis : peau artificielle

GENESIS CHALLENGE

Revolutionizing the area of wound healing with cell therapy by meeting the challenges of bioproduction.




Mon travail : Le cancer du colon




Evolution de la maladie

- La maladie du cancer du côlon peut se définir en plusieurs états (cancer localisé, cancer métastasé, décès du patient etc.)
- Les patients sont suivis pendant plusieurs années, et le médecin souhaiterait avoir un outil d'aide à la décision pour choisir le meilleur traitement en fonction des caractéristiques spécifiques du patient.

Mon travail : Modèle d'IA pour prédire l'évolution de la maladie



Modèle prédictif



Score de risque

- Développement d'un modèle de deep learning pour intégrer les caractéristiques du patient et prédire les risques d'évolution de la maladie.
- Ces prédictions aident le médecin à adapter le traitement ou le suivi du patient.

Mon quotidien

- Veille bibliographique
- Développement de modèles de deep learning
- Réunions avec des médecins pour comprendre l'enjeu médical et acquérir une expertise métier
- Participation à des conférences
- Objectifs Business / Stratégie d'entreprise (Présentation à la direction de l'entreprise, réunions avec mes supérieurs, séminaire)

Les compétences

- Lire des articles scientifiques (anglais)
- Communiquer en anglais (conférence, séminaires)
- Vulgariser devant des partenaires (médecins)
- Vulgariser devant ses collègues (ingénieurs)
- Encadrer des stagiaires
- Travailler en autonomie
- Savoir coder en Python / Pytorch
- Connaissances en développement (Linux)
- Maîtriser la théorie mathématique (niveau Master)
- Développer une expertise métier (oncologie)
- Connaître les enjeux juridiques/réglementaires

Programme de l'atelier

But de l'atelier

- Le but n'est pas de faire de la théorie (il y en aura légèrement)
- Vous faire pratiquer du concret : ce que peut être mon travail (pas exhaustive, et très raccourci pour tenir dans 24 heures)
- Vous faire utiliser les outils qu'on utilise vraiment. Pour le développement : UV, git, Pytorch


Notation

- Notation en contrôle continu (TP en continu)
- Projet finale avec une mini-soutenance et mini-rapport.
- Tout se fera en cours, pas de devoir à la maison.

Cas d'étude : La Cholangite Biliaire Primitive (CBP)

La CBP est une maladie chronique d'origine auto-immune. Le système immunitaire du patient se dérègle et attaque les petits canaux biliaires à l'intérieur du foie. Ces canaux servent normalement à évacuer la bile. Lorsqu'ils sont détruits, la bile s'accumule dans le foie (cholestase). Cette stagnation ronge le foie de l'intérieur, créant des cicatrices (fibrose).

Au fil des années, si les traitements médicamenteux ne suffisent pas, le foie devient dur et ne fonctionne plus : c'est le stade de la cirrhose décompensée. À ce stade, le pronostic vital est engagé à court terme. La seule issue curative est alors la transplantation du foie.



Étapes de la CBP

Cas d'étude : La Cholangite Biliaire Primitive (CBP)

Éligibilité du patient

Lorsqu'un patient atteint ce stade critique de la CBP, la question de la transplantation de foie est abordée par les médecins. Le dossier du patient est présenté en **Réunion de Concertation Pluridisciplinaire (RCP)** avec des hépatologues, chirurgiens, anesthésistes et autres experts du corps médical. Ces spécialistes répondent alors aux questions suivantes :

- Le patient est-il capable de supporter l'opération ?
- Existe-t-il des contre-indications à cette opération ? (comorbidités cardiaques trop lourdes, cancer métastasé etc.)

Si le patient est considéré comme capable de supporter l'opération et qu'il n'y a pas de contre-indications, le patient est inscrit sur la liste nationale d'attente de transplantation de foie.

Priorisation de la transplantation

Il y a beaucoup plus de patients nécessitant une transplantation de foie que de greffons de foie disponibles. La question est alors de définir quels sont les patients prioritaires pour une transplantation. On doit greffer celui qui a le plus grand risque de décéder à court terme.

La question est alors : **Comment quantifier le risque de décéder du patient ?**

Encore aujourd'hui, on utilise un score appelé le **score foie**. Ce score prend en compte plusieurs composantes :

- Un score représentant la gravité biologique (score MELD)
- Le cancer du patient (s'il est atteint d'un cancer du foie)
- Complications ou maladie rare du patient (composante dite "expert")
- La logistique (distance entre le donneur et le receveur)

Pour attribuer le greffon, on prend le patient ayant le score foie le plus haut tel que la greffe est compatible (même groupe sanguin entre le donneur et le receveur).

Super urgence

Dans des cas particulièrement urgent où un patient risque de décéder dans les 24 - 72 heures, une priorité peut lui être accordée.

Algorithme de priorisation de transplantation de foie

Cristal *receveurs*

Agence de la Biomédecine
Elisabeth PASDELOUP (PP7FA)

Aide Accueil Contacter l'administrateur Quitter

Liste Score Foie (hors composante distance)

Administration
 • Inscrire en attente
 • Tableau de bord
 • Liste de travail
 • Recherche patient
 • Patients à transférer
 • Indisponibilité des équipes

IR : 7
 NATT :
 ABO : A

Equipe : PP7FA
 Nom :

NEFG :
 Prénom :

Réinitialiser Filtrer

39 patients trouvés

Liste Score Foie (hors composante distance) == 12 ==

Equipe	NEFG	NATT	Nom	Prénom	ABO	Date fin CIT	MELD	SCORE	RgNat	NOTE	ALLOC
PP7FA	102460	191908			A		40	1000.0	1		RETR
PP7FA	172563	181561			A	20/12/2011	14	697.79	10		CHTNM2
PP7FA	145412	189199			A		25	551.31	23		MHNC
PP7FA	204200	189198			A		7	521.37	33		XPFB00
PP7FA	205636	189992			A		16	521.26	34		XPFB00
PP7FA	23876	191262			A		23	519.38	35		RETR
PP7FA	127619	190191			A	15/09/2011	23	500.2	41		CIRRH
PP7FA	203299	188648			A		22	470.93	51		CIRRH
PP7FA	27229	190088			A		22	470.79	54		CIRRH
PP7FA	193722	186730			A	31/12/2011	11	435.76	62		CHTNM2
PP7FA	175870	180464			A		18	435.27	63		MHNC
PP7FA	202134	188221			A		15	399.9	78		CHTNM2
PP7FA	204192	189196			A	30/09/2011	18	365.11	88		CHTNM1
PP7FA	208722	191543			A		18	353.0	96		CIRRH
PP7FA	191237	185109			A		17	324.23	107		CIRRH
PP7FA	206574	190398			A		17	304.75	123		MHNC
PP7FA	204565	189387			A	30/09/2011	16	299.57	125		MHNC
PP7FA	194612	187238			A		8	281.64	136		CHTNM2
PP7FA	205763	190060			A		15	264.91	148		CIRRH
PP7FA	194422	187117			A		14	235.79	158		CIRRH

Liste d'attente greffe de foie, Centre Hépato-Biliaire Paul Brousse

CRISTAL


L'Agence de la Biomédecine est une agence publique nationale créée par la loi de bioéthique de 2004. Elle recense tous les patients ayant besoin d'une greffe (cœur, rein, foie,...) et tous les donneurs potentiels par l'intermédiaire d'un registre informatisé : la base CRISTAL.

Le score MELD

Le score MELD (Model for End-Stage Liver Disease) est défini de la façon suivante

- Les Variables (Features) : Le score est calculé à partir de trois analyses sanguines objectives : la Bilirubine (fonction d'excrétion), l'INR (fonction de coagulation) et la Créatinine (fonction rénale).
- Le Calcul (Modèle) : Une formule logarithmique transforme ces valeurs en un score allant de 6 à 40.
- La Règle (Ranking) : Plus le MELD est élevé, plus la probabilité de décès à 3 mois est forte.

$$MELD = 3.78 \times \ln(bilirubine) + 11.2 \times \ln(INR) + 9.57 \times \ln(créatinine) + 6.43$$



The image shows a screenshot of a web-based table titled "MELD Score Normal Range" from the website www.drlogy.com. The table has three columns: "MELD Score", "Mortality Risk", and "Description". It contains four rows of data representing different score ranges and their associated mortality risks and descriptions. The table is framed by a light blue border with "Drlogy" and "Calculator" icons at the top corners. At the bottom, there are small liver icons and the website URL.

MELD Score	Mortality Risk	Description
6-9	6%	Low (2-6%)
10-19	19%	Medium (6-19%)
20-29	52%	High (20-52%)
30-40	71%	Very high (71%)

Score de MELD

Projet du cours

Les limitations concernant ce score peuvent être nombreuses :

- Le score MELD ne repose que sur 3 variables biologiques et ignore totalement les données cliniques autres et les données démographiques (age, sexe, etc.)
- Le score MELD est une “photo” à l’instant T, et ne capture pas la dynamique (vitesse d’aggravation) de la maladie.

Votre objectif

En tant que data scientist, votre objectif est de construire un modèle prédictif permettant de prédire le risque de décéder du patient tout en prenant en compte la complexité clinique que le score MELD ne permet pas de prendre en compte. Ce nouveau modèle pourrait permettre de mieux prioriser les patients et d’optimiser la transplantation de foie.

But de l'atelier

Pour créer cet outil d'aide à la décision clinique, nous allons uniquement nous occuper de la partie modèle prédictif (et non la partie développement logiciel)

Le plan de l'atelier est le suivant :

- Préparation de données cliniques
- Développement de modèle prédictif
- Etude d'un article scientifique pour améliorer le modèle prédictif
- Sujet de l'interprétabilité en IA

Ce dont vous aurez besoin :

- Un ordinateur.

Outils

Environnement de développement

- **VSCode** (*Microsoft*) est un éditeur de code open-source, léger et gratuit. Son avantage majeur est sa modularité : grâce à un immense marché d'extensions, il s'adapte à tous les langages. Il est devenu le standard pour sa polyvalence, intégrant nativement Git, le terminal et les Notebooks Jupyter dans une interface unifiée.
- **PyCharm** est un IDE complet, conçu spécifiquement pour Python. Son atout principal est sa robustesse "clés en main". Il offre des outils avancés d'analyse statique, de refactoring et de débogage sans configuration préalable. C'est l'outil de référence pour des projets exclusivement en Python.



PyCharm


Versioning

- **Git** est un système de contrôle de versions décentralisé qui s'installe sur votre machine. Il agit comme une “machine à remonter le temps” pour votre code. Son but principal est de sauvegarder l'historique de chaque modification, permettant de travailler sur plusieurs fonctionnalités en parallèle (branches) et d'annuler toute erreur instantanément.
- **GitHub** (*Microsoft*) est une plateforme cloud qui héberge vos projets Git. C'est l'espace de collaboration par excellence. Son avantage majeur est de centraliser le code pour permettre le travail en équipe : il facilite la sauvegarde distante et l'automatisation des tests.




Environnement virtuel python

- **Conda** est un gestionnaire de paquets et d'environnements multi-langages (Python, R, C++). Son but historique est de simplifier l'installation de bibliothèques scientifiques complexes (pré-compilées). Bien qu'il isole efficacement les projets, il est lourd à installer et son algorithme de résolution de dépendances est souvent très lent, ralentissant le flux de travail.
- **UV** est un gestionnaire de projet Python moderne, écrit en Rust. Il remplace avantageusement pip, poetry et venv. Son atout est sa performance écrasante : il est 10 à 100 fois plus rapide que Conda. Il garantit des environnements légers, respecte les standards modernes et offre une résolution de dépendances quasi-instantanée et déterministe.



Framework pour le deep learning

- **TensorFlow** (*Google*) est historiquement le pionnier industriel pour le deep learning. Il est conçu pour le déploiement de production à grande échelle. Cependant, il souffre d'une complexité héritée de sa gestion par graphe statique. Il reste très présent dans les infrastructures existantes des grandes entreprises (Legacy).
- **PyTorch** (*Meta*) est aujourd'hui le standard incontesté du Deep Learning. Son approche "Pythonic" et son graphe dynamique (on code le réseau comme du Python standard) rendent le débogage et l'expérimentation extrêmement intuitifs. C'est le moteur de la recherche mondiale et de l'IA Générative moderne, remplaçant progressivement TensorFlow partout.



Data

Les données en santé : anonymisation

Dans le domaine de la santé, les données sont souvent de mauvaises qualité. Deux facteurs principaux expliquent cette altération. Le premier est lié aux contraintes d'anonymisation des données de santé, enjeu majeur de la confidentialité pour les patients.

L'anonymisation est un compromis qui vise à préserver l'identité du patient tout en garantissant l'utilité statistique de la donnée. Pour anonymiser des données, on va chercher à enlever les informations jugées personnelles du patient (pseudonymisation) et à effectuer des méthodes de généralisation de la donnée pour empêcher la ré-identification.

Exemple de pseudonymisation:

- Supprimer le nom, l'adresse, la date de naissance
- Utiliser un identifiant dont seul le fournisseur de données (l'hôpital) peut avoir accès.

Exemple de méthode de généralisation:

	Vrai valeur	Valeur anonymisée
Age	22 ans	18 - 25 ans
Albumin	3.5 g/dL	< 5 g/dL
Ville	Paris	NA

Les données en santé : infrastructures

La deuxième raison principale de la mauvaise qualité des données en santé est la faiblesse des infrastructures et des ressources.

Les établissements manquent souvent de maturité technologique pour collecter une donnée propre :

- Pénurie de personnel qualifié pour traiter la donnée (Data Scientists, Data Engineers).
- Manque de ressources matérielles (serveurs de stockage)

Malgré une modernisation progressive, la culture médicale reste un frein à la structuration des données :

- Persistance des dossiers papier et des notes manuscrites.
- Préférence pour le texte libre (comptes-rendus narratifs) qui capture mieux la nuance clinique, mais reste très difficile à exploiter par des algorithmes d'IA.

L'ensemble de ces facteurs contribue à la mauvaise qualité des données, limitant leur exploitation par les modèles d'Intelligence Artificielle.

Acquisition des données

Les hôpitaux nous fournissent les données que nous utiliserons pour entraîner un modèle prédictif qui sera intégré dans l'outil d'aide à la décision clinique.

Cohorte rétrospective

Nous baserons notre étude sur une cohorte rétrospective historique, constituée par la Mayo Clinic. Elle regroupe 312 patients suivis entre 1974 et 1984 pour une Cholangite Biliaire Primitive (CBP).

Cette cohorte est précieuse par la qualité de son suivi longitudinal : sur une période s'étendant jusqu'à 10 ans, elle compile l'évolution clinique des patients au travers de visites régulières. Elle associe des données démographiques fixes à une série de biomarqueurs dynamiques (bilirubine, albumine, enzymes hépatiques). L'enjeu clinique majeur de cette étude est d'analyser ces trajectoires pour anticiper la survenue de l'événement terminal : le décès ou la transplantation hépatique.

Mayo Clinic

Référence mondiale à but non lucratif, la Mayo Clinic est un système hospitalo-universitaire américain d'excellence. Elle combine soins, recherche et éducation, fournissant des données cliniques d'une fiabilité exceptionnelle pour la recherche médicale.

A vous de jouer !

Objectif : Analyse exploratoire du jeu de données (EDA).

Je vous conseille les étapes suivantes :

1. **Setup** : Installer VSCode, Git, UV.
2. **Env** : Créer un environnement virtuel avec `uv init`.
3. **Data** : Récupérer le dataset sur le dépôt GitHub.

Le github :

https://github.com/Tmargate/M2_cours_ingenieur_sante


**Toutes les aides pour installer et utiliser les outils sont dans le pdf
Cheat sheet outils.pdf**

Analyse des données


Points de vigilance pour l'analyse

- **Outliers** : S'agit-il d'erreurs de saisie ou de cas pathologiques réels ?
- **Equilibre** : Les labels sont-ils équilibrés ?
- **Corrélations** : Faut-il supprimer les variables corrélées en médecine ?
- **Valeurs manquantes** : Sont-elles informatives ou aléatoires ?
- **Dates** : Format US ou FR ? Cohérence temporelle ?

Distribution des données



Distribution platelets




Distribution serBilir


Outliers

Parfois on peut avoir des données qui ne sont pas dans la même unité, ou bien le médecin à fait une erreur dans le remplissage du tableau.

Distribution des évènements



Distribution des évènements



Distribution des temps d'évènements


On remarque un déséquilibre dans la distribution des status (évènements cliniques observé). Cela pourrait-il être un problème pour l'apprentissage d'un algorithme de deep learning ?



Devons-nous supprimer l'une des deux variables ?

Il faut bien faire attention de ne pas inclure plusieurs fois le même patient en présence de données longitudinales !

Données manquantes



Est-ce que la donnée manquante est toujours un manque d'information ? Cela peut-il être un problème pour l'apprentissage d'un réseau de neurones ?

Nettoyage des données

- Supprimer la colonne date_diag (inutile car le temps de suivi est mesuré par rapport à t=0).
- Supprimer la colonne total_protein (trop corrélé à la variable albumin).
- Remettre la bonne valeur au patient 104 pour la variable serBilir (diviser par 100).
- Imputer les variables continues manquantes par la médiane
- Imputer les variables catégorielles manquantes par le mode
- Transformer les patients transplantés en patient censurés (status 2 devient 0).


Analyse de survie et modèle prédictif

Analyse de survie

Objectif : Prédire le risque de survenue d'un évènement au cours du temps.

- Prédire le risque de rechute du cancer pour un patient opéré chirurgicalement.
- Prédire le temps avant qu'une machine ne fonctionne plus.
- Prédire le risque qu'un client d'une banque ne puisse pas rembourser son prêt.

Dans notre cas d'étude, on cherchera à prédire le risque de décès du patient atteint de la Cholangite Biliaire Primitive au cours du temps.



Risque cumulé de décès d'un patient

Modélisation mathématique

Avant de définir un modèle prédictif, nous devons bien définir les quantités mathématiques que nous cherchons à prédire.

- Soit $\mathcal{X}_i$ les variables du patient i
- Soit T_i une variable aléatoire réelle représentant le temps d'évènement (temps de décès) du patient i
- T_i a alors une fonction de répartition, notée F_i , définie par

$$F_i(t|\mathcal{X}_i) = P(T_i \leq t|\mathcal{X}_i) \quad (1)$$

$F_i(t|\mathcal{X}_i)$ représente la probabilité que le patient soit décédé avant le temps t .

On définit alors la fonction de survie S , comme la probabilité que l'évènement (décès) ne s'est pas encore réalisé jusqu'à un certain temps.

$$S_i(t|\mathcal{X}_i) = 1 - F_i(t|\mathcal{X}_i) = P(T_i > t|\mathcal{X}_i) \quad (2)$$

Quantité à prédire

T_i (temps de décès) admet une densité de survie f_i , représentant le risque de décès du patient au cours du temps, définie par

$$f_i(t|\mathcal{X}_i) = \frac{dF_i(t|\mathcal{X}_i)}{dt} = P(t \in [T_i, T_i + dt]|\mathcal{X}_i) \quad (3)$$

- C'est cette quantité que nous allons chercher à prédire.

Par simplicité, nous allons travailler en temps discret. On cherchera donc à prédire $(f_i(t|\mathcal{X}_i))_{t \in \{1, \dots, T_{max}\}}$ avec

$$f_i(t|\mathcal{X}_i) = P(T_i = t|X_i) \quad (4)$$

et T_{max} un temps maximum définie (en général on prend le temps maximum d'étude clinique).

Prédiction par deep learning

Notre objectif est de développer un algorithme de deep learning capable de prédire la fonction de risque de décès f_i au cours du temps (discrétisé).

Nos 4 prochaines étapes sont les suivantes :


1. Définition de l'architecture du réseau
2. Définition et implémentation de la fonction de coût
3. Procédure d'entraînement (split data, training loop, etc.)
4. Définition et calcul des métriques de performance.

A vous de jouer pour proposer une architecture !

En connaissant les contraintes posées par la forme des données d'entrées (données tabulaires longitudinales) et la forme attendue des sorties de l'algorithme (distribution de probabilités au cours du temps discrétisé), vous êtes libre de choisir l'architecture de votre choix.

Architecture proposée

La structure des données d'entrées (format temporel) pousse naturellement à l'utilisation de réseau récurrent (type LSTM) comme première brique. On complète par un fully connected layer avec un nombre de neurones de sortie égal au nombre de temps dans la discrétisation temporelle. On applique une fonction softmax pour obtenir une distribution de probabilités (positive et somme à 1).



Architecture proposée

Valeur de prédiction

- L'architecture du réseau est cruciale pour définir “la forme” des prédictions, c'est-à-dire s'il s'agit de scalaires, de vecteurs d'une certaine taille, d'une distribution de probabilités etc.
- Cependant, l'architecture seule ne permet pas de définir la valeur de prédiction. Vous pouvez très bien avoir une même architecture utilisée pour deux tâches de prédiction complètement différentes. Les valeurs de prédictions (output de l'architecture) sont le résultat de l'optimisation de l'algorithme.

Nous cherchons à prédire le “vrai” risque de décès du patient, noté $f_i(t|\mathcal{X}_i) \forall t \in \{1, \dots, T_{max}\}$. Nos prédictions de ce risque sont notées $\hat{f}_i(t|\mathcal{X}_i) \forall t \in \{1, \dots, T_{max}\}$. Nous cherchons alors à minimiser la quantité suivante :

$$Loss = \sum_{t=1}^{T_{max}} \left(f_i(t|\mathcal{X}_i) - \hat{f}_i(t|\mathcal{X}_i) \right)^2 \quad (5)$$

Comment peut-on minimiser cette quantité alors que nous ne connaissons pas le “vrai” risque de décès du patient $f_i(t|\mathcal{X}_i)$?

Notion de vraisemblance

- Contrairement à la probabilité, qui prédit des données futures à partir d'un modèle connu, la vraisemblance part des données observées pour évaluer la qualité d'un modèle.
- La question clé : Sachant que j'ai observé ces données, quelle est la plausibilité que mes paramètres de modèle soient les bons?

On cherche les paramètres qui rendent nos observations les plus probables possibles. C'est l'estimation par le maximum de vraisemblance.


Vraisemblance

On définit la vraisemblance L pour les paramètres du modèle θ comme la probabilité de la réalisation des données observées sachant les paramètres du modèle.

$$L(\theta) = P(Data|\theta) \tag{6}$$

L'objectif est alors de maximiser la vraisemblance et d'estimer les paramètres qui la rendent maximale.

Courbe de vraisemblance



Courbe de vraisemblance

- $L(\theta) = P(\text{Data}|\theta)$: Vraisemblance
- θ : Paramètres du modèle
- $\hat{\theta}_{MLE}$: Estimateur des paramètres qui maximisent la vraisemblance

Vraisemblance pour nos données

- Il nous suffit alors de déterminer la vraisemblance, et nous chercherons à la maximiser par le processus d'optimisation de l'algorithme.

Question : Comment déterminer la vraisemblance ? Comment définir la quantité suivante en fonction de nos données:

$$L(\theta) = P(Data|\theta) \quad (7)$$

- Trouver une vraisemblance n'est pas un travail de calcul, ni informatique. C'est un travail de traduction et de "définition" de votre donnée.
- De quoi est composée votre donnée? Quelles sont les variables explicatives et les variables cibles (label)?
- Que sait-on sur les patients de notre jeu de données? Que ne sait-on pas?

Vraisemblance

La vraisemblance n'est rien d'autre que la traduction mathématique de la question "Quelle est la probabilité d'avoir observé ce qui s'est réellement passé pour ce patient"

Vraisemblance de survie

Pour un patient, nous connaissons ces variables cliniques au cours du temps, le temps auquel l'évènement survient et l'évènement (décès ou perte de vue).

Notre donnée sur un patient, noté $Data_i$, peut s'écrire de la forme suivante :

$$Data_i = \{\mathcal{X}_i, \tau_i, \delta_i\} \quad (8)$$

avec

- $\mathcal{X}_i$: les variables cliniques au cours du temps
- τ_i : le temps auquel l'évènement survient
- δ_i : indicateur de l'évènement (vaut 1 si le patient est décédé, 0 si le patient est perdu de vue)

Raisonnement :

- Si le patient est décédé, alors son risque de décès est maximal au temps auquel il est décédé
- Si le patient est perdu de vue (censuré), on sait qu'il a survécu jusqu'au temps auquel il est censuré : son risque de décès est donc minimal sur toute la période de suivi.

Vraisemblance de survie

Raisonnement :

- Si le patient est décédé, alors son risque de décès est maximal au temps auquel il est décédé. On maximise f au temps de décès
- Si le patient est perdu de vue (censuré), on sait qu'il a survécu jusqu'au temps auquel il est censuré : son risque de décès est donc minimal sur toute la période de suivi. On maximise S au temps de censure.

Vraisemblance de survie pour un patient :

$$L(\theta|\mathcal{X}_i) = f(\tau_i|\mathcal{X}_i)^{\delta_i} S(\tau_i|\mathcal{X}_i)^{1-\delta_i} \quad (9)$$

Pour l'ensemble des n patients, en supposant une distribution i.i.d., on a la vraisemblance suivante :

$$L(\theta) = \prod_{i=1}^n L(\theta|\mathcal{X}_i) = \prod_{i=1}^n f(\tau_i|\mathcal{X}_i)^{\delta_i} S(\tau_i|\mathcal{X}_i)^{1-\delta_i} \quad (10)$$

On cherche donc à maximiser cette vraisemblance.

Fonction de coût

Afin de réduire les coûts computationnels et les erreurs de calculs par l'ordinateur, on préfère souvent passer au logarithme pour transformer les produits en somme.

$$\log(L(\theta)) = \sum_{i=1}^n \delta_i \log(f(\tau_i|\mathcal{X}_i)) + (1 - \delta_i) \log(S(\tau_i|\mathcal{X}_i)) \quad (11)$$

En optimisation, on cherche plutôt à minimiser une quantité plutôt que maximiser. Les optimiseurs prévus dans les framework de deep learning sont d'ailleurs prévus pour minimiser.

Maximiser une fonction revient à minimiser son opposé. On va donc définir notre fonction de coût à minimiser comme l'opposé de la log-vraisemblance, noté $\mathcal{L}$

$$\mathcal{L}(\theta) = -\log(L(\theta)) = -\sum_{i=1}^n \delta_i \log(f(\tau_i|\mathcal{X}_i)) + (1 - \delta_i) \log(S(\tau_i|\mathcal{X}_i)) \quad (12)$$

Negative log likelihood

Les fonctions de coût basés sur la negative log likelihood sont courantes. Par exemple lorsqu'une assurance auto veut fixer le prix d'assurance pour un conducteur, un modèle va modéliser le nombre d'accidents le conducteur est susceptible d'avoir dans l'année. On modélise cela par un processus de Poisson, et on cherche à minimiser la negative log likelihood du processus.

Implémentation de la fonction de coût

- On rappelle que les prédictions de notre architecture sont les quantités $(\hat{f}(t|\mathcal{X}))_{t \in \{1, \dots, T_{max}\}}$
- La fonction de survie prédite est alors définie par $\hat{S}(t|\mathcal{X}) = \sum_{s=t+1}^{T_{max}} \hat{f}(s|\mathcal{X})$.
- Nous disposons dans nos données des temps d'évènements des patients τ ainsi que leur statut d'évènement δ
- La fonction de coût est la negative log likelihood $\mathcal{L}$ donnée par :

$$\mathcal{L} = - \sum_{i=1}^n \delta_i \log(\hat{f}(\tau_i|\mathcal{X}_i)) + (1 - \delta_i) \log(\hat{S}(\tau_i|\mathcal{X}_i)) \quad (13)$$

Implémentation

Nous devons implémenter la fonction (ou la classe) qui permet de calculer la negative log likelihood. Cette quantité sera calculé à chaque itération (chaque batch et chaque epoch), il vaut mieux l'écrire d'une façon la moins coûteuse computationnellement.

Objectif : Ne pas utiliser une seule boucle dans le code qui calcule la loss. Écrire un code vectorisé